Pemrosesan Bahasa Alami dan Model Bahasa Besar

1. Pemrosesan Bahasa Alami

Pemrosesan bahasa alami (NLP) adalah cabang AI yang memungkinkan komputer memahami dan menghasilkan bahasa manusia. Tugas umumnya meliputi klasifikasi sentimen, pengenalan entitas bernama, penerjemahan mesin, peringkasan, dan tanya jawab.

Bahasa Indonesia memiliki tantangan tersendiri, seperti imbuhan yang kaya, kata serapan, dan ragam bahasa tidak baku di media sosial.

2. Tokenisasi

Model tidak membaca huruf atau kata secara langsung, tetapi token. Tokenisasi subkata seperti Byte-Pair Encoding dan WordPiece memecah kata yang jarang muncul menjadi potongan yang lebih kecil, sehingga kosakata tetap terbatas namun hampir semua teks dapat direpresentasikan.

Jumlah token memengaruhi biaya dan batas panjang masukan. Teks dalam bahasa yang kurang terwakili dalam data pelatihan sering membutuhkan lebih banyak token untuk makna yang sama.

3. Representasi Kata

Word2vec yang diperkenalkan Mikolov dan kawan-kawan pada tahun 2013 melatih vektor kata sehingga kata dengan konteks mirip memiliki vektor yang berdekatan. GloVe adalah pendekatan lain yang memanfaatkan statistik kemunculan bersama kata.

Kelemahan vektor kata statis adalah satu kata hanya punya satu vektor, padahal maknanya bergantung pada konteks. Model kontekstual seperti BERT pada tahun 2018 menghasilkan vektor yang berbeda untuk kata yang sama pada kalimat yang berbeda.

4. Arsitektur Transformer

Transformer memakai mekanisme self-attention yang memungkinkan tiap token menimbang seberapa penting token lain dalam kalimat. Multi-head attention menjalankan beberapa perhatian secara paralel agar model dapat menangkap beragam hubungan sekaligus.

Karena tidak memproses token satu per satu, Transformer mudah dilatih secara paralel pada GPU. Informasi urutan ditambahkan melalui positional encoding.

5. Pelatihan Model Bahasa Besar

Model bahasa besar dipra-latih dengan tugas memprediksi token berikutnya pada korpus teks yang sangat besar. Dari tugas sederhana ini, model memperoleh pengetahuan bahasa dan dunia secara luas.

Tahap berikutnya adalah penyetelan dengan instruksi dan umpan balik manusia, yang dikenal sebagai RLHF, agar model mengikuti perintah dengan lebih berguna dan aman. Tahap ini tidak menjamin jawaban selalu benar.

Tabel 1. Tiga keluarga model berbasis Transformer

Keluarga	Struktur	Cocok untuk
BERT	Hanya encoder	Klasifikasi dan pengenalan entitas

GPT	Hanya decoder	Pembangkitan teks dan percakapan
T5	Encoder-decoder	Penerjemahan dan peringkasan

Sumber: ringkasan penulis.

6. Prompting dan Keterbatasan

Pada zero-shot prompting, model diberi instruksi tanpa contoh. Pada few-shot prompting, beberapa contoh disertakan dalam prompt. Teknik chain-of-thought meminta model menuliskan langkah penalaran sebelum jawaban akhir, yang sering meningkatkan hasil pada soal bernalar.

Keterbatasan utama model bahasa besar antara lain halusinasi, jendela konteks yang terbatas, dan pengetahuan yang berhenti pada tanggal batas data pelatihan. Karena itu, jawaban penting perlu diverifikasi.