Lab 1 - Eksperimen Chunking

Dikerjakan dengan Python (pdfplumber + fungsi potong)

Langkah 1. Membaca PDF dan memeriksa teks

File yang dibaca: sejarah_kecerdasan_buatan.pdf. Berikut 500 karakter pertama hasil baca_pdf():

```
Sejarah dan Perkembangan Kecerdasan Buatan
1. Awal Mula
Pada tahun 1950, Alan Turing menerbitkan makalah Computing Machinery and Intelligence yang
mengajukan pertanyaan apakah mesin dapat berpikir. Ia mengusulkan uji imitasi, yang kemudian
dikenal sebagai Turing Test, untuk menilai apakah jawaban mesin dapat dibedakan dari jawaban
manusia.
Istilah artificial intelligence pertama kali dipakai oleh John McCarthy dalam proposal Konferensi
Dartmouth pada tahun 1956. Pertemuan musim panas itu umumnya
```

Pemeriksaan	Hasil
File	sejarah_kecerdasan_buatan.pdf
Total karakter	3320
Karakter rusak (U+FFFD)	0
Persentase huruf	82%

Teks terbaca bersih: tidak ada karakter rusak, kata utuh, dan urutan paragraf benar. Satu catatan: teks Tabel 1 hasil ekstraksi tercampur antar kolom karena sel yang lebih dari satu baris digabung per baris tampilan, bukan per sel.

Langkah 2. Jumlah chunk tiap pengaturan

Fungsi potong(teks, ukuran, overlap) memakai jendela geser per karakter; langkah = ukuran x (1 - overlap).

Ukuran (karakter)	overlap 10%	overlap 15%	overlap 20%
500	8	8	9
1000	4	4	4
1500	3	3	3

Tabel 1. Jumlah chunk untuk 3 ukuran x 3 overlap. Makin besar ukuran, makin sedikit chunk; makin besar overlap, makin banyak chunk.

Langkah 3. Tiga chunk acak per ukuran (overlap 15%, seed 42)

Ukuran	Jumlah chunk	Awal di tengah kalimat	Akhir di tengah kalimat	Memotong tabel
500	8	7/8 (88%)	7/8 (88%)	2/8
1000	4	3/4 (75%)	3/4 (75%)	2/4
1500	3	2/3 (67%)	2/3 (67%)	2/3

Tabel 2. Statistik seluruh chunk pada tiap ukuran (bukan hanya yang dicuplik).

Ukuran 500 karakter

Chunk #1 (karakter 0-500) | awal di tengah kalimat: tidak | akhir di tengah kalimat: ya | memotong tabel: tidak

```
Sejarah dan Perkembangan Kecerdasan Buatan
1. Awal Mula
```

```
Pada tahun 1950, Alan Turing menerbitkan makalah Computing Machinery and Intelligence yang
mengajukan pertanyaan apakah mesin dapat berpikir. Ia mengusulkan uji imitasi, yang kemudian
dikenal sebagai Turing Test, untuk menilai apakah jawaban mesin dapat dibedakan dari jawaban
manusia.
Istilah artificial intelligence pertama kali dipakai oleh John McCarthy dalam proposal Konferensi
Dartmouth pada tahun 1956. Pertemuan musim panas itu umumnya
```

Chunk #2 (karakter 425-925) | awal di tengah kalimat: ya | akhir di tengah kalimat: ya | memotong tabel: tidak

```
sal Konferensi
Dartmouth pada tahun 1956. Pertemuan musim panas itu umumnya dianggap sebagai kelahiran AI
sebagai bidang ilmu.
2. Era Sistem Pakar
Pada tahun 1970-an dan 1980-an, banyak peneliti membangun sistem pakar yang menyimpan
pengetahuan pakar manusia dalam bentuk aturan jika-maka. MYCIN membantu mendiagnosis
infeksi bakteri dan merekomendasikan antibiotik, sedangkan DENDRAL membantu menebak
struktur molekul senyawa kimia.
Kelemahan sistem pakar adalah aturan harus ditulis tangan sehingga
```

Chunk #6 (karakter 2125-2625) | awal di tengah kalimat: ya | akhir di tengah kalimat: ya | memotong tabel: ya

```
nangan ini
memicu ledakan penelitian deep learning, dibantu oleh penggunaan GPU untuk pelatihan.
Pada tahun 2016, program AlphaGo milik DeepMind mengalahkan pemain Go profesional Lee
Sedol dengan skor 4 banding 1. Go dianggap jauh lebih sulit daripada catur karena jumlah
kemungkinan posisinya sangat besar.
Tabel 1. Tonggak sejarah kecerdasan buatan
Tahun Peristiwa Makna
1950 Makalah Turing tentang mesin Dasar gagasan uji kecerdasan
berpikir mesin
1956 Konferensi Dartmouth Kelahiran istilah dan b
```

Ukuran 1000 karakter

Chunk #1 (karakter 0-1000) | awal di tengah kalimat: tidak | akhir di tengah kalimat: ya | memotong tabel: tidak

```
Sejarah dan Perkembangan Kecerdasan Buatan
1. Awal Mula
Pada tahun 1950, Alan Turing menerbitkan makalah Computing Machinery and Intelligence yang
mengajukan pertanyaan apakah mesin dapat berpikir. Ia mengusulkan uji imitasi, yang kemudian
dikenal sebagai Turing Test, untuk menilai apakah jawaban mesin dapat dibedakan dari jawaban
manusia.
Istilah artificial intelligence pertama kali dipakai oleh John McCarthy dalam proposal Konferensi
Dartmouth pada tahun 1956. Pertemuan musim panas itu umumnya dianggap sebagai kelahiran AI
sebagai bidang ilmu.
2. Era Sistem Pakar
Pada tahun 1970-an dan 1980-an, banyak peneliti membangun sistem pakar yang menyimpan
pengetahuan pakar manusia dalam bentuk aturan jika-maka. MYCIN membantu mendiagnosis
infeksi bakteri dan merekomendasikan antibiotik, sedangkan DENDRAL membantu menebak
struktur molekul senyawa kimia.
Kelemahan sistem pakar adalah aturan harus ditulis tangan sehingga mahal dibuat dan sulit
dirawat. Sistem juga gagal ketika menghadapi situas
```

Chunk #3 (karakter 1700-2700) | awal di tengah kalimat: ya | akhir di tengah kalimat: ya | memotong tabel: ya

```
y! melawan dua juara manusia.
Pada masa ini, fokus bergeser dari aturan buatan tangan ke pembelajaran dari data. Tersedianya
data dalam jumlah besar dan komputer yang lebih murah membuat pendekatan statistik semakin
unggul.
5. Revolusi Deep Learning
Pada tahun 2012, jaringan saraf konvolusional bernama AlexNet memenangkan lomba pengenalan
gambar ImageNet dengan selisih galat yang jauh lebih kecil daripada pesaingnya. Kemenangan ini
memicu ledakan penelitian deep learning, dibantu oleh penggunaan GPU untuk pelatihan.
Pada tahun 2016, program AlphaGo milik DeepMind mengalahkan pemain Go profesional Lee
Sedol dengan skor 4 banding 1. Go dianggap jauh lebih sulit daripada catur karena jumlah
kemungkinan posisinya sangat besar.
Tabel 1. Tonggak sejarah kecerdasan buatan
Tahun Peristiwa Makna
1950 Makalah Turing tentang mesin Dasar gagasan uji kecerdasan
berpikir mesin
1956 Konferensi Dartmouth Kelahiran istilah dan bidang AI
1997 Deep Blue mengalahkan Kasparov Mesin unggul dalam catur
2012
```

Chunk #4 (karakter 2550-3320) | awal di tengah kalimat: ya | akhir di tengah kalimat: tidak | memotong tabel: ya

```
kecerdasan
berpikir mesin
1956 Konferensi Dartmouth Kelahiran istilah dan bidang AI
1997 Deep Blue mengalahkan Kasparov Mesin unggul dalam catur
2012 AlexNet menang di ImageNet Awal ledakan deep learning
2016 AlphaGo mengalahkan Lee Sedol Mesin unggul dalam permainan Go
2017 Arsitektur Transformer Dasar model bahasa besar
Sumber: ringkasan penulis.
6. Era Transformer dan AI Generatif
Pada tahun 2017, makalah Attention Is All You Need memperkenalkan arsitektur Transformer yang
bertumpu pada mekanisme perhatian. Arsitektur ini menjadi dasar model bahasa besar seperti
BERT dan GPT.
Pada November 2022, peluncuran ChatGPT membuat AI generatif dikenal luas oleh masyarakat
umum. Sejak itu, model yang menghasilkan teks, gambar, kode, dan suara berkembang sangat
cepat.
```

Ukuran 1500 karakter

Chunk #1 (karakter 0-1500) | awal di tengah kalimat: tidak | akhir di tengah kalimat: ya | memotong tabel: tidak

```
Sejarah dan Perkembangan Kecerdasan Buatan
1. Awal Mula
Pada tahun 1950, Alan Turing menerbitkan makalah Computing Machinery and Intelligence yang
mengajukan pertanyaan apakah mesin dapat berpikir. Ia mengusulkan uji imitasi, yang kemudian
dikenal sebagai Turing Test, untuk menilai apakah jawaban mesin dapat dibedakan dari jawaban
manusia.
Istilah artificial intelligence pertama kali dipakai oleh John McCarthy dalam proposal Konferensi
Dartmouth pada tahun 1956. Pertemuan musim panas itu umumnya dianggap sebagai kelahiran AI
sebagai bidang ilmu.
2. Era Sistem Pakar
Pada tahun 1970-an dan 1980-an, banyak peneliti membangun sistem pakar yang menyimpan
pengetahuan pakar manusia dalam bentuk aturan jika-maka. MYCIN membantu mendiagnosis
infeksi bakteri dan merekomendasikan antibiotik, sedangkan DENDRAL membantu menebak
struktur molekul senyawa kimia.
Kelemahan sistem pakar adalah aturan harus ditulis tangan sehingga mahal dibuat dan sulit
dirawat. Sistem juga gagal ketika menghadapi situasi di luar aturan yang telah ditulis.
3. Musim Dingin AI
Musim dingin AI adalah masa ketika harapan terhadap AI menurun dan dana penelitian dipangkas.
Laporan Lighthill pada tahun 1973 di Inggris mengkritik kemajuan AI yang dinilai jauh di bawah janji
awalnya, dan pendanaan pun menyusut.
Periode serupa terulang pada akhir 1980-an ketika pasar mesin khusus untuk bahasa
pemrograman AI runtuh. Pelajaran pentingnya adalah bahwa klaim yang berlebihan dapat
merugikan seluruh bidang.
4. Kebangkitan Pemb
```

Chunk #2 (karakter 1275-2775) | awal di tengah kalimat: ya | akhir di tengah kalimat: ya | memotong tabel: ya

```
un menyusut.
Periode serupa terulang pada akhir 1980-an ketika pasar mesin khusus untuk bahasa
pemrograman AI runtuh. Pelajaran pentingnya adalah bahwa klaim yang berlebihan dapat
merugikan seluruh bidang.
4. Kebangkitan Pembelajaran Mesin
Pada tahun 1997, komputer catur Deep Blue milik IBM mengalahkan juara dunia Garry Kasparov
dalam pertandingan enam partai. Pada tahun 2011, IBM Watson menang dalam kuis televisi
Jeopardy! melawan dua juara manusia.
Pada masa ini, fokus bergeser dari aturan buatan tangan ke pembelajaran dari data. Tersedianya
data dalam jumlah besar dan komputer yang lebih murah membuat pendekatan statistik semakin
unggul.
5. Revolusi Deep Learning
Pada tahun 2012, jaringan saraf konvolusional bernama AlexNet memenangkan lomba pengenalan
gambar ImageNet dengan selisih galat yang jauh lebih kecil daripada pesaingnya. Kemenangan ini
memicu ledakan penelitian deep learning, dibantu oleh penggunaan GPU untuk pelatihan.
Pada tahun 2016, program AlphaGo milik DeepMind mengalahkan pemain Go profesional Lee
Sedol dengan skor 4 banding 1. Go dianggap jauh lebih sulit daripada catur karena jumlah
kemungkinan posisinya sangat besar.
Tabel 1. Tonggak sejarah kecerdasan buatan
Tahun Peristiwa Makna
1950 Makalah Turing tentang mesin Dasar gagasan uji kecerdasan
berpikir mesin
1956 Konferensi Dartmouth Kelahiran istilah dan bidang AI
1997 Deep Blue mengalahkan Kasparov Mesin unggul dalam catur
2012 AlexNet menang di ImageNet Awal ledakan deep learning
2016 AlphaGo mengalah
```

Chunk #3 (karakter 2550-3320) | awal di tengah kalimat: ya | akhir di tengah kalimat: tidak | memotong tabel: ya

```
kecerdasan
berpikir mesin
1956 Konferensi Dartmouth Kelahiran istilah dan bidang AI
1997 Deep Blue mengalahkan Kasparov Mesin unggul dalam catur
2012 AlexNet menang di ImageNet Awal ledakan deep learning
2016 AlphaGo mengalahkan Lee Sedol Mesin unggul dalam permainan Go
2017 Arsitektur Transformer Dasar model bahasa besar
Sumber: ringkasan penulis.
6. Era Transformer dan AI Generatif
Pada tahun 2017, makalah Attention Is All You Need memperkenalkan arsitektur Transformer yang
bertumpu pada mekanisme perhatian. Arsitektur ini menjadi dasar model bahasa besar seperti
BERT dan GPT.
Pada November 2022, peluncuran ChatGPT membuat AI generatif dikenal luas oleh masyarakat
umum. Sejak itu, model yang menghasilkan teks, gambar, kode, dan suara berkembang sangat
cepat.
```

Kesimpulan

Pemotongan per karakter tidak mengenal batas kalimat maupun tabel. Hasil seluruh chunk (overlap 15%) - ukuran 500: awal 7/8 (88%), akhir 7/8 (88%), memotong tabel 2/8; ukuran 1000: awal 3/4 (75%), akhir 3/4 (75%), memotong tabel 2/4; ukuran 1500: awal 2/3 (67%), akhir 2/3 (67%), memotong tabel 2/3. Jadi pada setiap ukuran, mayoritas chunk berakhir di tengah kalimat dan sebagian besar juga dimulai di tengah kalimat (hanya chunk pertama yang selalu bersih). Persentasenya tidak turun banyak saat ukuran diperbesar; yang berubah adalah jumlah chunk dan banyaknya topik per chunk. Tabel 1 terpotong oleh sedikitnya satu chunk pada tiap ukuran, dan teks tabel hasil ekstraksi sudah bercampur antar kolom, sehingga baris tabel yang terpisah dari baris judulnya sulit dipahami. Perbaikan yang layak dicoba: pemotongan berbasis kalimat/paragraf dan memperlakukan tabel sebagai satu chunk utuh.

Lampiran: kode lab1_chunking.py

```
"""Lab 1 - Eksperimen chunking (15 menit).

1. Baca satu PDF dengan baca_pdf() dan cetak 500 karakter pertama.
2. Potong dengan potong() memakai tiga ukuran (500, 1000, 1500) dan overlap 10-20%.
3. Lihat 3 chunk acak tiap ukuran: terpotong di tengah kalimat atau tabel?
"""
import os
import random
import sys

sys.path.insert(0, os.path.dirname(os.path.abspath(__file__)))
from laporan_utils import Laporan
from rag_utils import FOLDER_DOKUMEN, baca_pdf, norm, potong, potong_dengan_posisi

BASE = os.path.dirname(os.path.abspath(__file__))
PDF = os.path.join(FOLDER_DOKUMEN, "sejarah_kecerdasan_buatan.pdf")   # ganti dengan PDF Anda
UKURAN = [500, 1000, 1500]
OVERLAP = [0.10, 0.15, 0.20]
OVERLAP_UTAMA = 0.15
SEED = 42


def wilayah_tabel(teks):
    """Cari rentang karakter tabel ("Tabel N." sampai baris "Sumber:")."""
    hasil, pos = [], 0
    while True:
        a = teks.find("Tabel ", pos)
        if a < 0:
            return hasil
        b = teks.find("Sumber:", a)
        b = len(teks) if b < 0 else teks.find("\n", b)
        hasil.append((a, b))
        pos = b


def awal_di_tengah_kalimat(teks, mulai):
    """Chunk dimulai di tengah kalimat bila karakter bermakna sebelumnya bukan akhir kalimat/baris."""
    sebelum = teks[:mulai].rstrip(" ")
    return bool(sebelum) and sebelum[-1] not in ".!?:\n"


def akhir_di_tengah_kalimat(teks, akhir):
    ujung = teks[:akhir].rstrip()
    return bool(ujung) and ujung[-1] not in ".!?"


def memotong_tabel(wil, mulai, akhir):
    """True bila chunk beririsan dengan tabel tetapi tidak memuat seluruh tabel."""
    for a, b in wil:
        beririsan = mulai < b and akhir > a
        utuh = mulai <= a and akhir >= b
        if beririsan and not utuh:
            return True
    return False


def main():
    # ---- Langkah 1
    teks = baca_pdf(PDF)
    n_huruf = sum(c.isalpha() for c in teks)
    kualitas = {
        "File": os.path.basename(PDF),
        "Total karakter": len(teks),
        "Karakter rusak (U+FFFD)": teks.count("\ufffd"),
        "Persentase huruf": f"{n_huruf / len(teks):.0%}",
    }
    print("=== Langkah 1: 500 karakter pertama ===")
    print(teks[:500])
    print(kualitas)

    # ---- Langkah 2
    print("\n=== Langkah 2: jumlah chunk ===")
    tabel_jumlah = [["Ukuran (karakter)"] + [f"overlap {int(o * 100)}%" for o in OVERLAP]]
    for u in UKURAN:
        baris = [u]
        for o in OVERLAP:
            n = len(potong(teks, u, o))
            baris.append(n)
            print(f"ukuran={u:5d} overlap={o:.0%} -> {n} chunk")
        tabel_jumlah.append(baris)
```

```
    # ---- Langkah 3
    wil = wilayah_tabel(teks)
    rnd = random.Random(SEED)
    cuplikan, statistik = {}, [["Ukuran", "Jumlah chunk", "Awal di tengah kalimat",
                                "Akhir di tengah kalimat", "Memotong tabel"]]
    for u in UKURAN:
        pot = potong_dengan_posisi(teks, u, OVERLAP_UTAMA)
        n = len(pot)
        a = sum(awal_di_tengah_kalimat(teks, m) for m, _, _ in pot)
        z = sum(akhir_di_tengah_kalimat(teks, e) for _, e, _ in pot)
        t = sum(memotong_tabel(wil, m, e) for m, e, _ in pot)
        statistik.append([u, n, f"{a}/{n} ({a / n:.0%})", f"{z}/{n} ({z / n:.0%})", f"{t}/{n}"])
        pilih = sorted(rnd.sample(range(n), min(3, n)))
        cuplikan[u] = [(i + 1, pot[i][0], pot[i][1], pot[i][2],
                        awal_di_tengah_kalimat(teks, pot[i][0]),
                        akhir_di_tengah_kalimat(teks, pot[i][1]),
                        memotong_tabel(wil, pot[i][0], pot[i][1])) for i in pilih]
        print(f"\n=== Langkah 3: ukuran {u} (3 chunk acak) ===")
        for no, m, e, isi, aw, ak, tb in cuplikan[u]:
            print(f"--- chunk #{no} [{m}:{e}] awal_tengah={aw} akhir_tengah={ak} potong_tabel={tb}")
            print(isi)

    # ---- Kesimpulan otomatis dari angka
    rincian = "; ".join(
        f"ukuran {r[0]}: awal {r[2]}, akhir {r[3]}, memotong tabel {r[4]}" for r in statistik[1:])
    kesimpulan = (
        "Pemotongan per karakter tidak mengenal batas kalimat maupun tabel. Hasil seluruh chunk (overlap
    "
        f"{int(OVERLAP_UTAMA * 100)}%) - {rincian}. Jadi pada setiap ukuran, mayoritas chunk berakhir di
    tengah "
        "kalimat dan sebagian besar juga dimulai di tengah kalimat (hanya chunk pertama yang selalu
    bersih). "
        "Persentasenya tidak turun banyak saat ukuran diperbesar; yang berubah adalah jumlah chunk dan "
        "banyaknya topik per chunk. Tabel 1 terpotong oleh sedikitnya satu chunk pada tiap ukuran, dan
    teks "
        "tabel hasil ekstraksi sudah bercampur antar kolom, sehingga baris tabel yang terpisah dari baris
     "
        "judulnya sulit dipahami. Perbaikan yang layak dicoba: pemotongan berbasis kalimat/paragraf dan "
        "memperlakukan tabel sebagai satu chunk utuh."
    )
    print("\nKesimpulan:", kesimpulan)

    # ---- Laporan PDF
    L = Laporan(os.path.join(BASE, "Lab1_Eksperimen_Chunking.pdf"),
                "Lab 1 - Eksperimen Chunking", "Dikerjakan dengan Python (pdfplumber + fungsi potong)")
    L.h1("Langkah 1. Membaca PDF dan memeriksa teks")
    L.p(f"File yang dibaca: {os.path.basename(PDF)}. Berikut 500 karakter pertama hasil baca_pdf():")
    L.kode(teks[:500])
    L.spasi()
    L.tabel([["Pemeriksaan", "Hasil"]] + [[k, v] for k, v in kualitas.items()], [6 * 28.35, 8 * 28.35])
    L.p("Teks terbaca bersih: tidak ada karakter rusak, kata utuh, dan urutan paragraf benar. "
        "Satu catatan: teks Tabel 1 hasil ekstraksi tercampur antar kolom karena sel yang lebih dari satu
     baris "
        "digabung per baris tampilan, bukan per sel.")
    L.h1("Langkah 2. Jumlah chunk tiap pengaturan")
    L.p("Fungsi potong(teks, ukuran, overlap) memakai jendela geser per karakter; langkah = ukuran x (1 -
     overlap).")
    L.tabel(tabel_jumlah)
    L.cap("Tabel 1. Jumlah chunk untuk 3 ukuran x 3 overlap. Makin besar ukuran, makin sedikit chunk; "
          "makin besar overlap, makin banyak chunk.")
    L.h1(f"Langkah 3. Tiga chunk acak per ukuran (overlap {int(OVERLAP_UTAMA * 100)}%, seed {SEED})")
    L.tabel(statistik)
    L.cap("Tabel 2. Statistik seluruh chunk pada tiap ukuran (bukan hanya yang dicuplik).")
    for u in UKURAN:
        L.h2(f"Ukuran {u} karakter")
        for no, m, e, isi, aw, ak, tb in cuplikan[u]:
            L.p(f"Chunk #{no} (karakter {m}-{e}) | awal di tengah kalimat: {'ya' if aw else 'tidak'} | "
                f"akhir di tengah kalimat: {'ya' if ak else 'tidak'} | memotong tabel: {'ya' if tb else
    'tidak'}")
            L.kode(isi)
            L.spasi(4)
    L.h1("Kesimpulan")
    L.p(kesimpulan)
    L.halaman_baru()
    L.h1("Lampiran: kode lab1_chunking.py")
    L.kode(open(__file__, encoding="utf-8").read())
    L.simpan()
    print("\nLaporan: Lab1_Eksperimen_Chunking.pdf")


if __name__ == "__main__":
    main()
```