Lab 3 - Ukur Hit@k

backend: lsa | overlap 15% | koleksi ukuran 500 dan 1000

Langkah 1. Lima belas pertanyaan uji

Soal dibuat dari tiga dokumen di folder dokumen/. Sebuah chunk dianggap benar bila memuat semua kata kunci jawaban. Sebanyak 7 soal bernada langsung dan 8 soal diparafrase (kata-katanya sengaja berbeda dari teks).

No	Jenis	Pertanyaan	Kata kunci
1	langsung	Siapa yang pertama kali memakai istilah artificial intelligence?	McCarthy
2	parafrase	Sistem apa yang membantu mendiagnosis infeksi bakteri pada era sistem pakar?	MYCIN
3	parafrase	Laporan apa pada tahun 1973 yang mengkritik kemajuan AI di Inggris?	Lighthill
4	langsung	Dengan skor berapa AlphaGo mengalahkan Lee Sedol?	4 banding 1
5	langsung	Makalah apa yang memperkenalkan arsitektur Transformer?	Attention Is All You Need
6	langsung	Siapa yang memperkenalkan perceptron pada tahun 1958?	Rosenblatt
7	langsung	Fungsi aktivasi apa yang menghasilkan nilai antara -1 dan 1?	tanh
8	parafrase	Fungsi apa yang mengubah skor keluaran menjadi probabilitas yang jumlahnya satu?	softmax
9	parafrase	Teknik apa yang mematikan sebagian neuron secara acak untuk mengurangi overfitting?	Dropout
10	parafrase	Arsitektur apa yang memakai gerbang untuk mengatur informasi yang disimpan atau dilupakan?	Long Short-Term Memory
11	langsung	Siapa yang memperkenalkan word2vec pada tahun 2013?	Mikolov
12	parafrase	Metode pemecahan kata menjadi potongan kecil apa yang dipakai agar kosakata tetap terbatas?	Byte-Pair Encoding
13	parafrase	Tahap penyetelan apa yang memakai umpan balik manusia agar model mengikuti perintah?	RLHF
14	parafrase	Teknik apa yang meminta model menuliskan langkah penalaran sebelum jawaban akhir?	chain-of-thought
15	langsung	Keluarga model apa yang cocok untuk penerjemahan dan peringkasan?	T5

Langkah 2. Hasil Hit@k

Koleksi	Hit@1	Hit@3	Hit@5	Jumlah chunk
ukuran 500	0.933	1.000	1.000	23
ukuran 1000	1.000	1.000	1.000	12

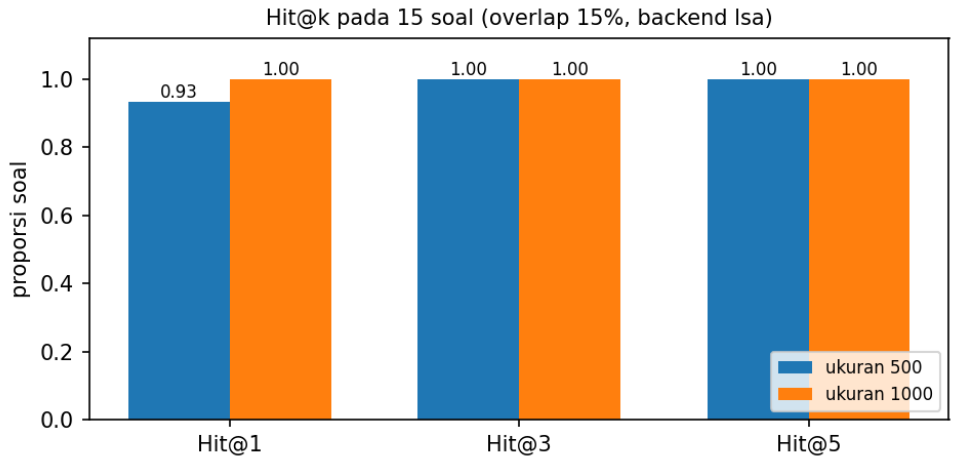

Hit@5 menurut jenis soal

Jenis soal	Jumlah	ukuran 500	ukuran 1000
langsung	7	1.000	1.000
parafrase	8	1.000	1.000

Peringkat chunk pertama yang memuat jawaban, per soal

Angka 1 berarti chunk teratas sudah benar. Angka > 5 berarti gagal pada Hit@5.

No	Jenis	Peringkat (ukuran 500)	Peringkat (ukuran 1000)
1	langsung	1	1
2	parafrase	1	1
3	parafrase	1	1
4	langsung	1	1
5	langsung	2	1
6	langsung	1	1
7	langsung	1	1
8	parafrase	1	1
9	parafrase	1	1
10	parafrase	1	1
11	langsung	1	1
12	parafrase	1	1
13	parafrase	1	1
14	parafrase	1	1
15	langsung	1	1

Langkah 3. Kesimpulan

Ukuran 1000 karakter lebih baik: Hit@1/3/5 = 1.00/1.00/1.00 dibanding 0.93/1.00/1.00 pada ukuran 500. Pada k=5, pertanyaan yang gagal: ukuran 500 -> tidak ada; ukuran 1000 -> tidak ada. Tidak ada kegagalan pada k=5, sehingga tidak ada penyebab yang perlu dianalisis. Catatan: skor mendekati sempurna karena korpus hanya 3 dokumen kecil (12-23 chunk) dengan topik yang jelas berbeda; pada PDF yang lebih besar dan lebih mirip antar dokumen, Hit@k diperkirakan turun dan perbedaan antar

ukuran chunk akan lebih terlihat.

Lampiran: kode lab3_hit_at_k.py

```
"""Lab 3 - Ukur Hit@k (25 menit).

1. 15 pertanyaan uji beserta kata kunci jawaban dari dokumen.
2. hit_at_k untuk k = 1, 3, 5 pada dua koleksi dengan ukuran chunk berbeda.
3. Kesimpulan 3-4 kalimat: ukuran terbaik, pertanyaan yang gagal, dugaan penyebab.
"""
import os
import sys

import matplotlib
matplotlib.use("Agg")
import matplotlib.pyplot as plt

sys.path.insert(0, os.path.dirname(os.path.abspath(__file__)))
from laporan_utils import Laporan
from rag_utils import FOLDER_DOKUMEN, baca_pdf, bangun_indeks, cocok, hit_at_k, norm, peringkat_hit

BASE = os.path.dirname(os.path.abspath(__file__))
OVERLAP = 0.15
UKURAN = (500, 1000)          # dua koleksi yang dibandingkan
KS = (1, 3, 5)

SOAL = [  # q = pertanyaan, kw = kata kunci yang harus ada di chunk jawaban, jenis = langsung / parafrase
    # --- sejarah_kecerdasan_buatan.pdf
    {"q": "Siapa yang pertama kali memakai istilah artificial intelligence?", "kw": ["McCarthy"],
    "jenis": "langsung"},
    {"q": "Sistem apa yang membantu mendiagnosis infeksi bakteri pada era sistem pakar?", "kw":
    ["MYCIN"], "jenis": "parafrase"},
    {"q": "Laporan apa pada tahun 1973 yang mengkritik kemajuan AI di Inggris?", "kw": ["Lighthill"],
    "jenis": "parafrase"},
    {"q": "Dengan skor berapa AlphaGo mengalahkan Lee Sedol?", "kw": ["4 banding 1"], "jenis":
    "langsung"},
    {"q": "Makalah apa yang memperkenalkan arsitektur Transformer?", "kw": ["Attention Is All You Need"],
     "jenis": "langsung"},
    # --- jaringan_saraf_deep_learning.pdf
    {"q": "Siapa yang memperkenalkan perceptron pada tahun 1958?", "kw": ["Rosenblatt"], "jenis":
    "langsung"},
    {"q": "Fungsi aktivasi apa yang menghasilkan nilai antara -1 dan 1?", "kw": ["tanh"], "jenis":
    "langsung"},
    {"q": "Fungsi apa yang mengubah skor keluaran menjadi probabilitas yang jumlahnya satu?", "kw":
    ["softmax"], "jenis": "parafrase"},
    {"q": "Teknik apa yang mematikan sebagian neuron secara acak untuk mengurangi overfitting?", "kw":
    ["Dropout"], "jenis": "parafrase"},
    {"q": "Arsitektur apa yang memakai gerbang untuk mengatur informasi yang disimpan atau dilupakan?",
    "kw": ["Long Short-Term Memory"], "jenis": "parafrase"},
    # --- nlp_model_bahasa_besar.pdf
    {"q": "Siapa yang memperkenalkan word2vec pada tahun 2013?", "kw": ["Mikolov"], "jenis": "langsung"},
    {"q": "Metode pemecahan kata menjadi potongan kecil apa yang dipakai agar kosakata tetap terbatas?",
    "kw": ["Byte-Pair Encoding"], "jenis": "parafrase"},
    {"q": "Tahap penyetelan apa yang memakai umpan balik manusia agar model mengikuti perintah?", "kw":
    ["RLHF"], "jenis": "parafrase"},
    {"q": "Teknik apa yang meminta model menuliskan langkah penalaran sebelum jawaban akhir?", "kw":
    ["chain-of-thought"], "jenis": "parafrase"},
    {"q": "Keluarga model apa yang cocok untuk penerjemahan dan peringkasan?", "kw": ["T5"], "jenis":
    "langsung"},  # jawaban ada di tabel
]


def diagnosis(idx, soal, k):
    """Tebak penyebab gagal secara otomatis dari data (bukan menebak sembarang)."""
    r = peringkat_hit(idx, soal)
    if r is None:
        return "kata kunci terbelah di batas chunk (tidak ada satu chunk pun yang memuatnya utuh)"
    return f"chunk jawaban ada tetapi baru muncul di peringkat {r} (> {k})"


def main():
    # sanity check: setiap kata kunci memang ada di dokumen asli
    korpus = norm(" ".join(baca_pdf(os.path.join(FOLDER_DOKUMEN, f))
                           for f in sorted(os.listdir(FOLDER_DOKUMEN)) if f.endswith(".pdf")))
    for s in SOAL:
        assert all(norm(k) in korpus for k in s["kw"]), f"kata kunci tidak ada di dokumen: {s}"

    koleksi, hasil = {}, {}
    for u in UKURAN:
        print(f"\n=== Koleksi ukuran {u} ===")
        koleksi[u] = bangun_indeks(ukuran=u, overlap=OVERLAP, backend="auto")
        hasil[u] = {k: hit_at_k(koleksi[u], SOAL, k) for k in KS}
        print({f"Hit@{k}": round(v, 3) for k, v in hasil[u].items()})
    backend = koleksi[UKURAN[0]].backend
```

```
ranks = {u: [peringkat_hit(koleksi[u], s) for s in SOAL] for u in UKURAN}

# ---- kesimpulan otomatis
kunci = lambda u: (hasil[u][5], hasil[u][3], hasil[u][1])
a, b = UKURAN
terbaik = a if kunci(a) > kunci(b) else b if kunci(b) > kunci(a) else None
fmt = lambda u: "/".join(f"{hasil[u][k]:.2f}" for k in KS)
if terbaik:
    lain = b if terbaik == a else a
    s1 = (f"Ukuran {terbaik} karakter lebih baik: Hit@1/3/5 = {fmt(terbaik)} dibanding {fmt(lain)}
pada "
          f"ukuran {lain}.")
else:
    s1 = f"Kedua ukuran seimbang: Hit@1/3/5 = {fmt(a)} (ukuran {a}) dan {fmt(b)} (ukuran {b})."
gagal = {u: [i for i, r in enumerate(ranks[u], 1) if r is None or r > 5] for u in UKURAN}
s2 = "Pada k=5, pertanyaan yang gagal: " + "; ".join(
    f"ukuran {u} -> " + (", ".join(f"no. {i}" for i in gagal[u]) if gagal[u] else "tidak ada") for u
in UKURAN) + "."
penyebab = {}
for u in UKURAN:
    for i in gagal[u]:
        penyebab[(u, i)] = diagnosis(koleksi[u], SOAL[i - 1], 5)
print("\nDiagnosis gagal (k=5):")
for (u, i), c in penyebab.items():
    print(f"  ukuran {u}, no. {i} ({SOAL[i-1]['q']}): {c}")

# hit@k per jenis soal (langsung vs parafrase)
per_jenis = {}
for jenis in ("langsung", "parafrase"):
    sub = [s for s in SOAL if s["jenis"] == jenis]
    per_jenis[jenis] = (len(sub), {u: hit_at_k(koleksi[u], sub, 5) for u in UKURAN})

# kalimat 3: dugaan penyebab berdasarkan jenis diagnosis
if penyebab:
    terbelah = [x for x in penyebab.values() if x.startswith("kata kunci terbelah")]
    peringkat = [x for x in penyebab.values() if x.startswith("chunk jawaban ada")]
    dugaan = []
    if peringkat:
        dugaan.append("kosakata pertanyaan berbeda dari kosakata dokumen (parafrase, mis. istilah
Indonesia "
                      "vs istilah Inggris di teks), dan chunk kecil memuat lebih sedikit kata konteks
 sehingga "
                      "skor kemiripannya kalah dari chunk lain yang topiknya lebih umum")
    if terbelah:
        dugaan.append("kata kunci jawaban terbelah di batas chunk dan overlap belum cukup
menyelamatkannya")
    s3 = "Dugaan penyebab: " + "; serta ".join(dugaan) + "."
else:
    s3 = "Tidak ada kegagalan pada k=5, sehingga tidak ada penyebab yang perlu dianalisis."
n_chunk = sorted(len(koleksi[u].chunks) for u in UKURAN)
rentang = f"{n_chunk[0]}-{n_chunk[-1]} chunk"
if max(hasil[u][5] for u in UKURAN) >= 0.9:
    s4 = (f"Catatan: skor mendekati sempurna karena korpus hanya 3 dokumen kecil ({rentang}) dengan
topik yang "
          "jelas berbeda; pada PDF yang lebih besar dan lebih mirip antar dokumen, Hit@k diperkirakan
 turun dan "
          "perbedaan antar ukuran chunk akan lebih terlihat.")
else:
    s4 = (f"Catatan: korpus hanya 3 dokumen kecil ({rentang}), sehingga satu soal yang gagal sudah
mengubah "
          "skor cukup besar; hasil ini belum tentu berlaku pada PDF yang lebih besar.")
kesimpulan = " ".join([s1, s2, s3, s4])
print("\nKesimpulan:", kesimpulan)

# grafik
fig, ax = plt.subplots(figsize=(6.4, 3.2), dpi=150)
lebar = 0.35
for j, u in enumerate(UKURAN):
    xs = [i + (j - 0.5) * lebar for i in range(len(KS))]
    bars = ax.bar(xs, [hasil[u][k] for k in KS], lebar, label=f"ukuran {u}")
    ax.bar_label(bars, fmt="%.2f", fontsize=8)
ax.set_xticks(range(len(KS)), [f"Hit@{k}" for k in KS])
ax.set_ylim(0, 1.12)
ax.set_ylabel("proporsi soal")
ax.set_title(f"Hit@k pada 15 soal (overlap {int(OVERLAP * 100)}%, backend {backend})", fontsize=10)
ax.legend(loc="lower right", fontsize=8)
fig.tight_layout()
gambar = os.path.join(BASE, "_grafik_hit_at_k.png")
fig.savefig(gambar)
plt.close(fig)

# laporan PDF
W = 28.35
```

```
    L = Laporan(os.path.join(BASE, "Lab3_Hit_at_k.pdf"), "Lab 3 - Ukur Hit@k",
                f"backend: {backend} | overlap {int(OVERLAP * 100)}% | koleksi ukuran {UKURAN[0]} dan
    {UKURAN[1]}")
    L.h1("Langkah 1. Lima belas pertanyaan uji")
    n_lgs = sum(s["jenis"] == "langsung" for s in SOAL)
    L.p("Soal dibuat dari tiga dokumen di folder dokumen/. Sebuah chunk dianggap benar bila memuat semua
    kata kunci "
        f"jawaban. Sebanyak {n_lgs} soal bernada langsung dan {len(SOAL) - n_lgs} soal diparafrase "
        "(kata-katanya sengaja berbeda dari teks).")
    L.tabel([["No", "Jenis", "Pertanyaan", "Kata kunci"]] +
            [[i, s["jenis"], s["q"], ", ".join(s["kw"])] for i, s in enumerate(SOAL, 1)],
            [1 * W, 2 * W, 10 * W, 4 * W])
    L.h1("Langkah 2. Hasil Hit@k")
    L.tabel([["Koleksi"] + [f"Hit@{k}" for k in KS] + ["Jumlah chunk"]] +
            [[f"ukuran {u}"] + [f"{hasil[u][k]:.3f}" for k in KS] + [len(koleksi[u].chunks)] for u in
    UKURAN],
            [4 * W, 2.5 * W, 2.5 * W, 2.5 * W, 3 * W])
    L.gambar(gambar, 13)
    L.h2("Hit@5 menurut jenis soal")
    L.tabel([["Jenis soal", "Jumlah"] + [f"ukuran {u}" for u in UKURAN]] +
            [[j, n] + [f"{v[u]:.3f}" for u in UKURAN] for j, (n, v) in per_jenis.items()],
            [4 * W, 2.5 * W, 3 * W, 3 * W])
    L.h2("Peringkat chunk pertama yang memuat jawaban, per soal")
    L.p("Angka 1 berarti chunk teratas sudah benar. Angka > 5 berarti gagal pada Hit@5.")
    L.tabel([["No", "Jenis", f"Peringkat (ukuran {UKURAN[0]})", f"Peringkat (ukuran {UKURAN[1]})"]] +
            [[i, s["jenis"], ranks[UKURAN[0]][i - 1], ranks[UKURAN[1]][i - 1]] for i, s in
    enumerate(SOAL, 1)],
            [1.2 * W, 3 * W, 5 * W, 5 * W])
    if penyebab:
        L.h2("Diagnosis soal yang gagal (k=5)")
        L.tabel([["Ukuran", "No", "Pertanyaan", "Diagnosis"]] +
                [[u, i, SOAL[i - 1]["q"], c] for (u, i), c in penyebab.items()], [1.5 * W, 1 * W, 7 * W,
    8 * W])
    L.h1("Langkah 3. Kesimpulan")
    L.p(kesimpulan)
    L.halaman_baru()
    L.h1("Lampiran: kode lab3_hit_at_k.py")
    L.kode(open(__file__, encoding="utf-8").read())
    L.simpan()
    os.remove(gambar)
    print("\nLaporan: Lab3_Hit_at_k.pdf")


if __name__ == "__main__":
    main()
```